

Optimización Numérica de Funciones en Varias Variables

Ingeniería en Computadores
Instituto Tecnológico de Costa Rica

CE-3102: Análisis Numéricos para Ingeniería

Juan Pablo Soto Quirós
jusoto@tec.ac.cr

- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal
 - Convergencia
 - Ejercicios

- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal
 - Convergencia
 - Ejercicios

- Esta presentación explica algunos aspectos matemáticos y computacionales sobre dos métodos iterativos para resolver problemas de minimización para funciones en varias variables.
- En especial, daremos énfasis en los siguientes dos métodos:
 - Método de Descenso Coordinado
 - Método del Gradiente Conjugado

1 Introducción

2 Problema de Optimización para una Función Multivariable

3 Método de Descenso Coordinado

- Convergencia
- Ejercicios

4 Método del Gradiente Conjugado No Lineal

- Convergencia
- Ejercicios

Función multivariable

Una función escalar de n variables $f : \mathbb{R}^n \rightarrow \mathbb{R}$, asigna a cada punto $(x_1, \dots, x_n) \in \mathbb{R}^n$, un único número real denotado con $f(x_1, \dots, x_n) \in \mathbb{R}$.

Problema

Sea $\mathbf{x} = (x_1, \dots, x_n)$. El objetivo de esta presentación es explicar un conjunto de métodos iterativos que permitirán dar una solución al problema de minimización

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}).$$

- En resumen, los pasos para resolver el problema

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$

en un curso de cálculo en varias variables son los siguientes:

- 1 Calcular los puntos críticos (Gradiente).
- 2 Calcular el Hessiano Orlado (Hessiano Orlado).
- 3 Evaluar puntos críticos en el Hessiano Orlado.
- 4 Calcular determinantes de las submatrices principales.
- 5 Interpretar resultado.

- La solución del problema $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$ se realizará a través de métodos iterativos.
- Es decir, dado un valor inicial $\mathbf{x}^{(0)} \in \mathbb{R}^n$, cada método iterativo generará una sucesión de puntos

$$\{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(k)}, \dots\},$$

donde $\mathbf{x}^{(j)} \in \mathbb{R}^n$, para todo $j = 1, 2, \dots$

- La sucesión de puntos puede tener tres criterios de convergencia:
 - 1 La sucesión converge a la solución del problema.
 - 2 La sucesión converge a un punto que no es solución del problema.
 - 3 La sucesión no converge.

- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado**
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal
 - Convergencia
 - Ejercicios

- El método de descenso coordinado (DC) actualiza solo una de las variables mientras las otras variables son “fijadas”.
- Existen varias reglas para seleccionar cual variable es actualizadas. Las tres reglas más utilizadas son:
 1. **Regla de Jacobian:** en cada iteración k , las n variables son actualizadas, utilizando exactamente los valores de la iteración anterior $k - 1$.

$$x_j^{(k)} \in \arg \min_{x_j \in \mathbb{R}} f \left(x_1^{(k-1)}, \dots, x_{j-1}^{(k-1)}, x_j, x_{j+1}^{(k-1)}, \dots, x_n^{(k-1)} \right),$$

para $j = 1, \dots, p$. Esta actualización se puede hacer en paralelo.

2. **Reglas de Gauss-Seidel:** en cada iteración k , las n variables son actualizadas, utilizando exactamente los valores de la iteración anterior $k - 1$, y los valores de la iteración k calculados anteriormente.

$$x_j^{(k)} \in \arg \min_{x_j \in \mathbb{R}} f \left(x_1^{(k)}, \dots, x_{j-1}^{(k)}, x_j, x_{j+1}^{(k-1)}, \dots, x_n^{(k-1)} \right),$$

para $j = 1, \dots, n$.

3. **Reglas Aleatorizada:** es una variación de la regla de Gauss-Seidel, pero la selección de la variable se hace de manera aleatoria, sin seguir un orden establecido.

Observación: De las 3 reglas mencionadas, la regla de Gauss-Seidel es la más utilizada.

Algorithm 1 Método de Optimización Alternada

Requires: $\mathbf{x}^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)}) \in \mathbb{R}^n$

Returns: $\mathbf{x}^{(k)} = (x_1^{(k)}, \dots, x_n^{(k)}) \in \mathbb{R}^n$

```

1: for  $k = 1, 2, \dots$  do
2:   for  $j = 1, \dots, n$  do
3:      $x_j^{(k)}$  = Usando la regla de Jacobi o Gauss-Seidel
4:   end
5:   if el criterio de parada se cumple then
6:     return  $x^{(k)} = (x_1^{(k)}, \dots, x_n^{(k)})$ 
7:   end
8: end

```

Ejemplo 1

Considere la función $f(x, y) = (x - 2)^2 + (y + 3)^2 + xy$. Aplique el método DC con la regla de Gauss-Seidel y $\mathbf{x}^{(0)} = (1, 1)^t$, utilizando 9 iteraciones.

Solución:

- **Iteración 1:** Calcular vector $\mathbf{x}^{(1)} = (x^{(1)}, y^{(1)})^t$
 - Calcular $x^{(1)}$. Para esto, se resuelve el problema

$$x^{(1)} = \arg \min_{x \in \mathbb{R}} f(x, y^{(0)}) = \arg \min_{x \in \mathbb{R}} f(x, 1) = \arg \min_{x \in \mathbb{R}} (x^2 - 3x + 20) = 1.5$$

- Calcular $y^{(1)}$. Para esto, se resuelve el problema

$$y^{(1)} = \arg \min_{y \in \mathbb{R}} f(x^{(1)}, y) = \arg \min_{y \in \mathbb{R}} f(1.5, y) = \arg \min_{x \in \mathbb{R}} \frac{4y^2 + 30y + 37}{4} = -3.75.$$

Por lo tanto, $\mathbf{x}^{(1)} = (1.5, -3.75)^t$.

Solución (Continuación):

- **Iteración 2:** Calcular vector $\mathbf{x}^{(2)} = (x^{(2)}, y^{(2)})^t$
 - Calcular $x^{(2)}$. Para esto, se resuelve el problema

$$x^{(2)} = \arg \min_{x \in \mathbb{R}} f(x, y^{(1)}) = \arg \min_{x \in \mathbb{R}} \frac{16x^2 - 124x + 73}{16} = 3.875.$$

- Calcular $y^{(2)}$. Para esto, se resuelve el problema


$$y^{(2)} = \arg \min_{y \in \mathbb{R}} f(x^{(2)}, y) = \arg \min_{y \in \mathbb{R}} \frac{8y^2 + 79y + 87}{8} = -4.9375.$$

Por lo tanto, $\mathbf{x}^{(2)} = (3.875, -4.9375)^t$.

Solución (Continuación):

Repitiendo el proceso varias veces, obtenemos los siguientes resultados:

k	$\mathbf{x}^{(k)}$	$f(\mathbf{x}^{(k)})$
0	(1, 1)	18
1	(1.5, -3.75)	-4.8125
2	(3.875, -4.9375)	-11.8633
3	(4.4688, -5.2344)	-12.3040
\vdots	\vdots	\vdots
9	(4.666, -5.333)	-12.3333



Ejemplo 2

Considere la función $f(x, y, z) = x^3 + y^3 + z^3 - 2xy - 2xz - 2yz$.
Aplicando el método OA con la regla de Gauss-Seidel y $\mathbf{x}^{(0)} = (1, 1, 1)^t$, obtenemos los siguientes resultados.

Solución:

k	$\mathbf{x}^{(k)}$	$f(\mathbf{x}^{(k)})$
0	(1, 1, 1)	3
1	(1.1547, 1.1985, 1.2525)	3.4366
2	(1.2641, 1.2953, 1.3062)	3.5392
\vdots	\vdots	\vdots
8	(1.333, 1.333, 1.333)	3.5556

Criterio de Parada

Dado una tolerancia $tol > 0$, dos criterios de parada para el método DC es considerar las siguientes expresiones booleanas:

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|_2 < tol \quad \text{ó} \quad \|\nabla f(\mathbf{x}^{(k+1)})\|_2 < tol$$

donde $\mathbf{x}^{(k)} \in \mathbb{R}^n$ es la k -ésima iteración generada por el método DC y $\|\cdot\|_2$

es la norma euclídeana definida por $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$.


- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado**
 - **Convergencia**
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal
 - Convergencia
 - Ejercicios

Algunas definiciones

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$.

- El **epigrafo** de f se define como el conjunto

$$\text{epi}(f) = \{(\mathbf{x}, \gamma) : f(\mathbf{x}) \leq \gamma, \forall \mathbf{x} \in \mathbb{R}^n, \gamma \in \mathbb{R}\}.$$



- Una función f es **cerrada** si su epigrafo es cerrado.

Algunas definiciones (continuación)

- Un punto $\mathbf{x}^* \in \mathbb{R}^n$ se llama **mínimo coordinado** si

$$f(\mathbf{x}^*) \leq f(\mathbf{x}^* + \alpha \cdot \mathbf{e}_j),$$

para $j = 1, \dots, n$ y $\alpha \in \mathbb{R}$. Aquí, $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ es la base canónica en \mathbb{R}^n .





Figura: Gráfica de la función $f(x, y) = |x - 2y| + |3x + 4y|$.

Algunas definiciones (continuación)

- Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ se llama convexa si cualesquiera dos puntos $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, y para cada $\alpha \in [0, 1]$, se cumple que

$$f(\alpha \mathbf{x} + (1 - \alpha) \mathbf{y}) \leq \alpha f(\mathbf{x}) + (1 - \alpha) f(\mathbf{y}).$$

- Una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es una función **apropiada** si no existe ningún punto \mathbf{x} tal que $f(\mathbf{x}) = -\infty$ y cuyo dominio no es vacío.

Teorema de Convergencia del Método DC

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función apropiada y cerrada, la cual es continua en su dominio. Si se cumple que

- 1 el problema $\min_{x_j \in \mathbb{R}} f \left(x_1^{(k)}, \dots, x_{j-1}^{(k)}, x_j, x_{j+1}^{(k-1)}, \dots, x_n^{(k-1)} \right)$ tiene una solución única, para todo $j = 1, \dots, n$
- 2 para cualquier $\mathbf{x}^{(0)}$, el conjunto $\{\mathbf{x} \in \mathbb{R}^n : f(\mathbf{x}) \leq f(\mathbf{x}^{(0)})\}$ es un conjunto acotado

entonces la sucesión generada por el método DC converge a un mínimo coordinado.

Nota: Si $f(\mathbf{x}) = g(\mathbf{x}) + \sum_{i=1}^n h_i(x_i)$, donde g es una función convexa y diferenciable, y cada h_i es convexa (no necesariamente diferenciable), entonces un mínimo coordinado de f es también un mínimo global de f .

- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado**
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal
 - Convergencia
 - Ejercicios

Ejercicios

- ❶ Considere la función

$$f(x, y, z) = (x - 2)^2 + (y + 3)^2 + (x + y + z)^2.$$

Aplique el método DC con un valor inicial $\mathbf{x}^{(0)} = (1, 1, 1)^t$, con una tolerancia de 10^{-3} .

- ❷ Considere la matriz $X = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ y el vector $\mathbf{y} = (-2, 3)^t$. Usando el método DC, resuelva el problema de optimización

$$\min_{\mathbf{z} \in \mathbb{R}^2} \frac{1}{2} \|\mathbf{y} - X\mathbf{z}\|_2^2,$$

con un valor inicial $\mathbf{z}^{(0)} = (0.5, 0.5)^t$, con una tolerancia de 10^{-3} .

- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal**
 - Convergencia
 - Ejercicios

- El método del gradiente conjugado no lineal (GCNL) es un algoritmo para resolver numéricamente el problema de optimización

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}),$$

donde f es una función continuamente diferenciable.

- Dado un valor inicial $\mathbf{x}^{(0)} \in \mathbb{R}^n$, el objetivo del método GCNL es crear una sucesión de puntos $\{\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(k)}, \dots\}$.
- Esta sucesión se genera mediante la siguiente fórmula

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

donde

- $\alpha_k > 0$ es un tamaño de paso obtenido por una búsqueda lineal
- $\mathbf{d}^{(k)} \in \mathbb{R}^n$ es una dirección de descenso en $\mathbf{x}^{(k)}$ de f

Selección de la dirección $\mathbf{d}^{(k)}$

- La dirección $\mathbf{d}^{(k)}$ es generada por la regla

$$\mathbf{d}^{(0)} = -\mathbf{g}^{(0)}, \quad \mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)},$$

donde $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})^t$ es el gradiente de f representado como un vector columna.

- La constante $\beta_k > 0$ es un parámetro de actualización del método GCNL.
- Diferentes métodos GCNL corresponden a diferentes elecciones para el escalar β_k .

$\beta_k^{HS} = \frac{\mathbf{g}_{k+1}^\top \mathbf{y}_k}{\mathbf{d}_k^\top \mathbf{y}_k}$	(1952)	in the original (linear) CG paper of Hestenes and Stiefel [59]
$\beta_k^{FR} = \frac{\ \mathbf{g}_{k+1}\ ^2}{\ \mathbf{g}_k\ ^2}$	(1964)	first nonlinear CG method, proposed by Fletcher and Reeves [45]
$\beta_k^D = \frac{\mathbf{g}_{k+1}^\top \nabla^2 f(\mathbf{x}_k) \mathbf{d}_k}{\mathbf{d}_k^\top \nabla^2 f(\mathbf{x}_k) \mathbf{d}_k}$	(1967)	proposed by Daniel [39], requires evaluation of the Hessian $\nabla^2 f(\mathbf{x})$
$\beta_k^{PRP} = \frac{\mathbf{g}_{k+1}^\top \mathbf{y}_k}{\ \mathbf{g}_k\ ^2}$	(1969)	proposed by Polak and Ribière [84] and by Polyak [85]
$\beta_k^{CD} = \frac{\ \mathbf{g}_{k+1}\ ^2}{-\mathbf{d}_k^\top \mathbf{g}_k}$	(1987)	proposed by Fletcher [44], CD stands for “Conjugate Descent”
$\beta_k^{LS} = \frac{\mathbf{g}_{k+1}^\top \mathbf{y}_k}{-\mathbf{d}_k^\top \mathbf{g}_k}$	(1991)	proposed by Liu and Storey [67]
$\beta_k^{DY} = \frac{\ \mathbf{g}_{k+1}\ ^2}{\mathbf{d}_k^\top \mathbf{y}_k}$	(1999)	proposed by Dai and Yuan [27]
$\beta_k^N = \left(\mathbf{y}_k - 2\mathbf{d}_k \frac{\ \mathbf{y}_k\ ^2}{\mathbf{d}_k^\top \mathbf{y}_k} \right)^\top \frac{\mathbf{g}_{k+1}}{\mathbf{d}_k^\top \mathbf{y}_k}$	(2005)	proposed by Hager and Zhang [53]

Figura: Posibles elecciones para el parámetro β_k . (Nota: $\mathbf{y}_k = \mathbf{g}_{k+1} - \mathbf{g}_k$)

Selección del tamaño de paso α_k

- En cada iteración del método GCNL, el paso α_k se escoge de resolver el siguiente problema de optimización:

$$\min_{\alpha \geq 0} f(\mathbf{x}^k + \alpha \mathbf{d}^k).$$

- En la práctica, uno no resuelve este problema. Una alternativa es encontrar la constante α_k que satisface la siguiente desigualdad

$$f(\mathbf{x}^k + \alpha_k \mathbf{d}^k) - f(\mathbf{x}^k) \leq \delta \alpha_k (\mathbf{g}^{(k)})^t \mathbf{d}^k, \quad (1)$$

donde $\delta \in]0, 1[$, el cual se elige de manera aleatoria.

- Dado $\alpha_k = 1$, se prueba α_k en la desigualdad (1). Si la desigualdad no se cumple, entonces se divide α_k por un número entero positivo (por ejemplo 2). El proceso se repite hasta que la desigualdad sea verdadera.

Algoritmo del método GCNL

REQUIRE: $\mathbf{x}^{(0)} \in \mathbb{R}^n$. **ENSURE:** $\mathbf{x}^{(k+1)} \in \mathbb{R}^n$

$$\mathbf{g}^{(0)} = \nabla f(\mathbf{x}^{(0)})^t; \quad \mathbf{d}^{(0)} = -\mathbf{g}^{(0)}$$

for $k = 0, 1, 2, \dots$ **do**

$$\alpha_k = 1; \quad \delta \in]0, 1[$$

while $\neg[f(\mathbf{x}^k + \alpha_k \mathbf{d}^k) - f(\mathbf{x}^k) \leq \delta \alpha_k (\mathbf{g}^{(k)})^t \mathbf{d}^k]$ **do**

$$\quad \alpha_k = \alpha_k / 2$$

end

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$$

if *stopping criterion is satisfied* **then**

 Return $\mathbf{x}^{(k+1)}$

end

$$\mathbf{g}^{(k+1)} = \nabla f(\mathbf{x}^{(k+1)})^t; \quad \text{Choose } \beta_k \text{ rule}$$

$$\mathbf{d}^{(k+1)} = -\mathbf{g}^{(k+1)} + \beta_k \mathbf{d}^{(k)}$$

end

Ejemplo 3

Considere la función $f(x, y) = (x - 2)^4 + (x - 2y)^2$. Aplique el método GCNL con $\mathbf{x}^{(0)} = (0, 3)^t$, utilizando 13 iteraciones, y usando la regla de Fletcher y Reeves $\beta_k = \frac{\|\mathbf{g}^{(k+1)}\|^2}{\|\mathbf{g}^{(k)}\|^2}$.

Solución: Sea $\nabla f(\mathbf{x}) = (4x^3 - 24x^2 + 50x - 4y - 32, -4x + 8y)$. Luego, se define $\mathbf{g}^{(0)} = \nabla f(\mathbf{x}^{(0)})^t = (-44, 24)^t$ y $\mathbf{d}^{(0)} = -\mathbf{g}^{(0)}$

● Iteración 1:

- Usando $\delta = 0.5$, buscamos el α_0 que cumple la condición (1) ([Ver bloque azul en Algoritmo GCNL](#)). En este caso, $\alpha_0 = 0.0625$.
- Se aproxima la primera iteración

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{d}^{(0)} = (1.375, 2.25)^t$$

- Se calcula $\mathbf{g}^{(1)} = \nabla f(\mathbf{x}^{(1)})^t = (-7.2265625, 12.5)^t$
- Se obtiene $\beta_0 = \frac{\|\mathbf{g}^{(1)}\|^2}{\|\mathbf{g}^{(0)}\|^2} = 0.082991$
- Se calcula $\mathbf{d}^{(1)} = -\mathbf{g}^{(1)} + \beta_0 \mathbf{d}^{(0)} = (10.878163, -14.491782)^t$

Solución: (Continuación)

● Iteración 2:

- Usando $\delta = 0.5$, buscamos el α_1 que cumple la condición (1) (Ver bloque azul en Algoritmo GCNL). En este caso, $\alpha_1 = 0.0625$.
- Se aproxima la segunda iteración


$$\mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \alpha_1 \mathbf{d}^{(1)} = (2.054885, 1.344264)^t$$

- Se calcula $\mathbf{g}^{(2)} = \nabla f(\mathbf{x}^{(2)})^t = (-4.889568, 2.534572)^t$
- Se obtiene $\beta_2 = \frac{\|\mathbf{g}^{(2)}\|^2}{\|\mathbf{g}^{(1)}\|^2} = 0.038510$
- Se calcula $\mathbf{d}^{(2)} = -\mathbf{g}^{(2)} + \beta_1 \mathbf{d}^{(1)} = (1.685541, -3.092645)^t$

Solución: (Continuación)

La siguiente tabla representa el cálculo de las siguientes iteraciones

k	$\mathbf{x}^{(k)}$	$\ \nabla f(\mathbf{x}^{(k)})\ $
0	$(0, 3)^t$	50.12
1	$(1.375, 2.25)^t$	14.4386
2	$(2.0549, 1.3443)^t$	2.8334
3	$(2.1602, 1.1510)^t$	0.62659
4	$(2.1821, 1.1061)^t$	0.12575
5	$(2.1852, 1.0968)^t$	0.034372
6	$(2.1849, 1.0940)^t$	0.022743
\vdots	\vdots	\vdots
13	$(2.0555, 1.0278)^t$	0.00062670



- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal**
 - Convergencia**
 - Ejercicios

Convergencia del Método CGNL

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una función apropiada, la cual es continua en su dominio. Si se cumple que

- para cualquier $\mathbf{x}^{(0)}$, el conjunto $\{\mathbf{x} \in \mathbb{R}^n : f(\mathbf{x}) \leq f(\mathbf{x}^{(0)})\}$ es un conjunto acotado
- Existe $A \subseteq \mathbb{R}^n$, tal que para todo $\mathbf{x}, \mathbf{y} \in A$, existe $L > 0$ tal que

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|.$$

- La constante δ del Método CGNL esta en el intervalo $]0, 0.5[$.
- entonces la sucesión generada por el método CGNL satisface

$$\lim_{k \rightarrow \infty} \|\nabla f(\mathbf{x}^{(k)})\| = 0.$$

- 1 Introducción
- 2 Problema de Optimización para una Función Multivariable
- 3 Método de Descenso Coordinado
 - Convergencia
 - Ejercicios
- 4 Método del Gradiente Conjugado No Lineal**
 - Convergencia
 - Ejercicios**

Ejercicios

- ❶ Considere la función

$$f(x_1, x_2) = xe^{-x^2-y^2}.$$

Aplique el método GCNL con un valor inicial $\mathbf{x}^{(0)} = (-0.5, -0.5)^t$, con una tolerancia de 10^{-2} .

- ❷ Considere la matriz $X = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$ y el vector $\mathbf{b} = (4, 7)^t$. Usando el método CGNL, resuelva el problema de optimización

$$\min_{\mathbf{x} \in \mathbb{R}^2} \left(\frac{1}{2} \mathbf{x}^t A \mathbf{x} - \mathbf{b}^t \mathbf{x} \right),$$

con un valor inicial $\mathbf{x}^{(0)} = (0.5, 0.5)^t$, con una tolerancia de 10^{-3} .